



Formation Apache Doris

De la théorie à la pratique

Présenté par : Eugénie Barlet, Aya Mecheri, Nico Dena et Perrine Ibourou

22 octobre 2025

Déroulement de la séance

1 Présentation

Introduction à Apache Doris et concepts clés

~15 minutes

2 Démonstration

Installation et première prise en main

~15 minutes

3 Travaux Dirigés

Analyses OLAP les résultats des matchs internationaux de football

~120 minutes

4 Correction

Débriefing et mise à disposition du corrigé

Qu'est-ce que Apache Doris ?

Un entrepôt de données **OLAP** en temps réel basé sur l'architecture **MPP** (Massive Parallel Processing), connu pour sa rapidité d'exécution des requêtes.



Requêtes ultra-rapides

Sub-secondes - Scannez 1 milliard de lignes en < 1 seconde



Haute concurrence

Des milliers d'utilisateurs simultanés sans dégradation



Analyses complexes à haut débit

Jointures, agrégations, window functions en temps réel

5000+

Entreprises utilisatrices

600+

Contributeurs

120+

Contributeurs actifs/mois

The screenshot shows the Apache Doris playground interface. On the left, there's a sidebar with a tree view of databases: __internal_schema, information_schema, mysql, and results_foot, with results selected. The main area has tabs for Editor, Format, System, Log, QueryProfile, Session, and Configuration. Below these is a search bar and a 'Clear the editor' button. The central part of the screen shows a 'Data Preview' tab with a table schema and data. The schema includes columns: date, home_team, away_team, home_score, away_score, tournament, city, country, and ne. The data preview displays several rows of football match results from 1873 to 1887, such as England vs Scotland on 1873-03-08 with a score of 4-2.



3-10x plus rapide
que les solutions
OLAP traditionnelles



Installation simplifiée
vs ClickHouse



Compatible MySQL
Protocole et syntaxe

De projet interne à leader mondial

2008-2013

Origines chez Baidu

Créé sous le nom de **Palo** pour gérer le reporting publicitaire de Baidu.

Développé en interne pour traiter **des milliards de requêtes quotidiennes** en temps réel.

Juillet 2018

Apache Incubator

Rejoint l'Apache Software Foundation en tant que **projet incubateur**. Renommé de "Palo" à "Apache Doris" et développé sous la supervision de mentors Apache.

Aujourd'hui (2025)

Écosystème Mature

Utilisé en production par **5000+ entreprises** dans le monde entier, incluant des géants comme TikTok, Xiaomi, Tencent, et Meituan. Adoption massive dans la finance, le retail, les télécoms, l'énergie et la santé.

2017

Open Source

Officiellement open-sourcé par Baidu sur **GitHub**, rendant la technologie accessible à la communauté mondiale.

Juin 2022

Top-Level Project

Diplômé avec succès de l'incubateur Apache et devient un **projet de premier niveau** (Top-Level Project).

Apache Doris dans l'écosystème data moderne

Le parcours de la donnée

Sources → Données brutes

Bases transactionnelles, APIs, fichiers, applications métier

ETL → Extraction et transformation

Extraction et transformation des données via des pipelines

- **Talaxie Open Studio** : orchestration visuelle des flux
- **Apache Hop** : pipelines de données

Stockage → Persistance

Stockage des données selon leur nature

- **Data Lake** : données brutes et non structurées
- **Data Warehouse** : données structurées


Apache Doris → Analyse ultra-rapide

Le moteur de requêtes temps réel qui lit directement depuis le stockage et répond en sub-seconde aux questions analytiques complexes.

Consommation → Utilisateurs finaux

Restitution via les outils métier

- **BI** (Power BI, Qlik) : dashboards et rapports
- **Data Science** (Dataiku) : ML et analyses avancées



Une architecture minimalist et puissante

Apache Doris possède une **architecture minimalist** avec seulement **deux types de processus**, ce qui réduit considérablement les coûts d'exploitation et de maintenance d'un système distribué.

Frontend (FE)

- ❖ Gestion des requêtes utilisateur
- ❖ Analyse et planification des requêtes (Query Planner)
- ❖ Gestion des métadonnées (schémas, tables, partitions)
- ❖ Gestion du cluster (coordination des nœuds)

Backend (BE)

- ❖ Stockage des données (colonnes, partitions, répliques)
- ❖ Exécution des plans de requêtes
- ❖ Traitement parallèle massivement distribué (**MPP**)

MPP = Massive Parallel Processing

Au lieu de traiter la requête sur un seul serveur, Doris la **découpe** et l'exécute **simultanément sur tous les nœuds Backend**. Chaque BE traite sa portion de données en parallèle, puis les résultats sont agrégés.

Résultat : performance **multipliée par le nombre de nœuds !**



5 raisons d'adopter cette architecture

-  **Scalabilité horizontale** : Ajoutez des FE/BE à chaud pour augmenter les capacités
-  **Haute disponibilité** : Réplication automatique des métadonnées et données avec tolérance aux pannes
-  **Maintenance simplifiée** : Aucune dépendance externe (pas de Zookeeper, HDFS, etc.)
-  **Compatible MySQL** : Connexion via protocole MySQL standard (DBeaver, clients MySQL, etc.)
-  **Stockage optimisé** : Format colonnes avec compression intelligente et indexation avancée

Sécurité et gestion des utilisateurs

Apache Doris intègre un **système de gestion des droits robuste**, permettant de contrôler finement l'accès aux données et de créer des environnements multi-utilisateurs sécurisés.

Contrôle d'accès RBAC

- ❖ **Role-Based Access Control** : Gestion par rôles
- ❖ Contrôle d'accès au niveau des **bases de données et tables**
- ❖ Rôles personnalisables avec **héritage de permissions**
- ❖ Gestion granulaire : SELECT, INSERT, UPDATE, DELETE, ALTER

Exemple de configuration

```
-- Créer un utilisateur  
CREATE USER 'etudiant'@'%' IDENTIFIED BY 'password';  
-- Créer un rôle "analyste"  
CREATE ROLE 'analyste';  
-- Donner les droits de lecture au rôle  
GRANT SELECT ON db.* TO ROLE 'analyste';  
-- Assigner le rôle à l'utilisateur  
GRANT 'analyste' TO 'etudiant'@'%';
```

 **Sécurité additionnelle** : Support SSL/TLS, authentification LDAP, et intégration avec Apache Ranger pour une gestion centralisée

Success Story : 10 000+ requêtes/jour chez Xiaomi



Comment Xiaomi utilise Apache Doris pour l'analyse temps réel à grande échelle

Depuis 2019, Xiaomi a déployé Apache Doris dans des **dizaines de départements** avec des centaines de nœuds pour répondre aux besoins croissants d'analyse de données. Doris gère désormais la **majorité des analyses en ligne** de l'entreprise.

40+

Clusters déployés à travers l'entreprise

100+

Noeuds dans le plus grand cluster

10k+

Requêtes d'analyse exécutées chaque jour

Cas d'utilisation chez Xiaomi



Plateforme A/B Test

Tests et expérimentations produit



Analyse de croissance

Métriques business temps réel



Analyse financière

Traitement des données financières



Dashboards

Pour tous les groupes commerciaux



Profils utilisateurs

Analyse comportementale des clients



Publicité

Mesure des performances des campagnes

Conclusion et ressources

Apache Doris en 3 points clés

✓ Architecture MPP pour l'OLAP temps réel

TraITEMENT parallèle sur tous les nœuds pour des performances sub-seconde

✓ Architecture minimaliste

Seulement 2 types de processus (FE/BE), facile à déployer

✓ Compatible MySQL et facilement intégrable

Protocole MySQL standard, connexion via DBeaver, Power BI, etc.

Quand choisir Apache Doris ?

- ❖ Analyses temps réel avec forte concurrence
- ❖ Dashboards et reporting interactifs
- ❖ Requêtes analytiques complexes (jointures, agrégations)



Ressources pour aller plus loin



Site officiel : doris.apache.org



Documentation : doris.apache.org/docs



Code source : github.com/apache/doris

Plan de la démonstration

Les étapes pour mettre Apache Doris en action (~15 minutes)

1 Vérification de l'environnement

Vérification que Apache Doris (via Docker) est bien démarré et connexion via DBeaver

2 Crédation d'une base de données

Commande SQL simple pour créer notre environnement de travail

3 Crédation d'une table

Définition du schéma avec types de colonnes, partitionnement et modèle de données

4 Import de données

Chargement d'un échantillon de données pour tester les requêtes

5 Première requête analytique

Exécution d'un SELECT avec agrégation pour démontrer les capacités OLAP

6 Visualisation des performances

Analyse du temps d'exécution

À vous de jouer !

⚽ Cas pratique : Analysez 150 ans de football mondial !

47 000+ matchs internationaux à explorer avec Apache Doris

⌚ Durée du TD : 2 heures

The screenshot displays a dataset page for "International football results from 1872 to 2025". Key details shown include:

- Dataset Overview:** An up-to-date dataset of over 47,000 international football results.
- Content Summary:** Includes 47,917 results from 1872 to 2025, ranging from FFA World Cup to FFI World Cup to regular friendly matches.
- Columns:** The file includes columns for date, name of the match, and name of the home team.
- Usage Statistics:** 10,000 users have viewed the dataset.
- Licenses:** CC0 - Public Domain.
- Frequency:** Monthly updates.
- Tags:** Sports, Football, History, Global, International Relations.

😊 Question du jour :

Les données feront-elles ressortir la meilleure équipe et le meilleur joueur... ou vos affinités personnelles vont-elles biaiser vos analyses ?